上海电机学院

硕士学位论文

基于深度学习的电机故障诊断方法研究

学科专业：电气工程

作者姓名：张三

学　号：　2023010001

指导教师：李明　教授

学　院：　电气学院

二〇二六年六月

上海电机学院
毕业设计（论文）学术诚信声明

本人郑重声明：所呈交的毕业设计（论文），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者签名：_____ 日期：_____

上海电机学院
毕业设计（论文）版权使用授权书

本毕业设计（论文）作者同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海电机学院可以将本毕业设计（论文）全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本毕业设计（论文）。

本论文属于

保密 □，在_____ 年解密后适用本授权书。

不保密 □。

（请在以上方框内打“✓”）

作者签名：_____　　指导教师签名：_____

日期：_____　　日期：_____

摘 要

电机作为工业生产中最重要的动力设备之一，其安全可靠运行对保障生产效率和设备安全具有重要意义。然而，电机在长期运行过程中不可避免地会出现各种故障，若不能及时发现和处理，将导致停机事故和经济损失。传统的电机故障诊断方法主要依赖人工经验判断和信号处理技术，存在诊断准确率低、泛化能力差等问题。

本文针对电机故障诊断中特征提取困难、诊断精度不足的问题，提出了一种基于深度学习的电机故障诊断方法。主要研究内容包括：（1）分析了电机常见故障类型及其振动信号特征，建立了电机故障振动信号数据集；（2）提出了一种基于卷积神经网络的端到端故障诊断方法，直接从原始振动信号中自动学习故障特征，避免了传统方法中复杂的人工特征提取过程；（3）引入迁移学习策略，解决了工业场景中小样本条件下模型训练困难的问题；（4）设计了一种多尺度特征融合网络结构，有效提高了模型对不同类型故障的识别能力。

实验结果表明，本文提出的方法在电机故障诊断任务中取得了 95.6% 的平均准确率，优于传统的支持向量机和随机森林等方法，同时在小样本场景下仍能保持较高的诊断精度，验证了该方法的有效性和实用性。

关键词：电机故障诊断，深度学习，卷积神经网络，迁移学习，特征提取

ABSTRACT

As one of the most important power equipment in industrial production, the safe and reliable operation of motors is of great significance to ensuring production efficiency and equipment safety. However, various faults inevitably occur during long-term operation of motors. If not detected and handled in time, they will lead to shutdown accidents and economic losses. Traditional motor fault diagnosis methods mainly rely on manual experience judgment and signal processing technology, which have problems such as low diagnostic accuracy and poor generalization ability.

This thesis proposes a motor fault diagnosis method based on deep learning to address the problems of difficult feature extraction and insufficient diagnostic accuracy in motor fault diagnosis. The main research contents include: (1) analyzing common fault types of motors and their vibration signal characteristics, and establishing a motor fault vibration signal dataset; (2) proposing an end-to-end fault diagnosis method based on convolutional neural network, which automatically learns fault features directly from raw vibration signals, avoiding the complex manual feature extraction process in traditional methods; (3) introducing transfer learning strategy to solve the problem of difficult model training under small sample conditions in industrial scenarios; (4) designing a multi-scale feature fusion network structure to effectively improve the model's ability to recognize different types of faults.

Experimental results show that the method proposed in this thesis achieves an average accuracy of 95.6% in motor fault diagnosis tasks, outperforming traditional methods such as support vector machine and random forest. Meanwhile, it can still maintain high diagnostic accuracy under small sample scenarios, verifying the effectiveness and practicality of the proposed method.

Key words: Motor Fault Diagnosis, Deep Learning, Convolutional Neural Network, Transfer Learning, Feature Extraction

目 录

摘 要 I
ABSTRACT II
目 录 III
1 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 1
1.2.1 基于传统方法的电机故障诊断研究 1
1.2.2 基于深度学习的电机故障诊断研究 1
1.2.3 现有研究的不足 2
1.3 本文主要研究内容 2
1.4 本文组织结构 2
2 相关理论基础 3
2.1 电机故障类型与机理 3
2.1.1 轴承故障 3
2.1.2 转子故障 3
2.2 深度学习基础理论 3
2.2.1 卷积神经网络 3
2.2.2 迁移学习 3
2.3 本章小结 4
3 基于 CNN 的端到端电机故障诊断方法 5
3.1 方法概述 5
3.2 网络结构设计 5
3.2.1 输入层 5
3.2.2 特征提取模块 5
3.2.3 分类模块 5
3.3 实验设置与结果分析 5
3.3.1 数据集 5
3.3.2 实验结果 5
3.4 本章小结 6
4 基于迁移学习的小样本电机故障诊断方法 7
4.1 问题分析 7
4.2 迁移学习策略设计 7
4.2.1 源域与目标域定义 7
4.2.2 预训练-微调策略 7
4.3 实验结果与分析 7
4.3.1 小样本实验设置 7

4.3.2 实验结果 7
4.4 本章小结 8
5 基于多尺度特征融合的电机故障诊断方法 9
5.1 问题分析 9
5.2 多尺度特征融合网络设计 9
5.2.1 网络总体结构 9
5.2.2 多尺度特征提取模块 9
5.2.3 特征融合模块 9
5.3 实验结果与分析 9
5.3.1 实验设置 9
5.3.2 对比实验结果 9
5.4 本章小结 10
6 总结与展望 11
6.1 本文工作总结 11
6.2 存在的不足 11
6.3 未来工作展望 11
致 谢 12
附录 A 附录：实验数据与代码 13
A.1 实验环境 13
A.2 超参数设置 13
攻读硕士学位期间取得的成果 14

图目录

表目录

表 3-1　不同方法在 CWRU 数据集上的诊断准确率 5
表 4-1　不同方法在小样本条件下的诊断准确率 (%) 7
表 5-1　不同方法在两个数据集上的诊断准确率 (%) 9
表 A-1　实验环境配置 13
表 A-2　模型训练超参数设置 13

1 绪论

1.1 研究背景与意义

电机是现代工业生产中应用最广泛的动力设备之一，广泛应用于电力、冶金、石化、制造等领域。据统计，全球工业用电量的 70% 以上由电机消耗，电机的安全可靠运行直接关系到生产效率和设备安全[nandi2005condition]。然而，电机在长期运行过程中，由于电气、机械、热力等多种因素的耦合作用，不可避免地会出现各种故障。常见的电机故障包括轴承故障、转子故障、定子故障和气隙偏心等，其中轴承故障约占电机故障总数的 40%～50%[zhang2020bearing]。

传统的电机故障诊断方法主要包括基于信号处理的方法和基于模型的方法。基于信号处理的方法通常需要先提取振动信号或电流信号的时域、频域或时频域特征，再利用分类器进行故障识别。这类方法严重依赖人工特征提取的经验和技巧，不同特征提取方法对诊断结果影响较大，且泛化能力有限[lei2020applications]。基于模型的方法需要建立精确的电机数学模型，但在实际工业环境中，模型参数往往难以精确获取，限制了其工程应用。

近年来，深度学习技术在图像识别、自然语言处理等领域取得了突破性进展，为电机故障诊断提供了新的技术途径。深度学习能够自动从原始数据中学习多层次的特征表示，避免了人工特征提取的局限性，有望实现端到端的智能故障诊断[zhao2019deep]。然而，将深度学习应用于电机故障诊断仍面临以下挑战：（1）工业现场故障样本稀缺，难以满足深度学习模型的大样本训练需求；（2）不同工况下信号特征差异大，模型的泛化能力有待提高；（3）深度学习模型的可解释性较差，难以满足工业应用的可信度要求。

因此，研究基于深度学习的电机故障诊断方法，对于提高电机故障诊断的准确性和智能化水平，保障工业生产的安全稳定运行，具有重要的理论意义和工程应用价值。

1.2 国内外研究现状

1.2.1 基于传统方法的电机故障诊断研究

传统的电机故障诊断方法主要分为基于信号处理的方法和基于模型的方法两大类。在信号处理方面，快速傅里叶变换（FFT）、小波变换、经验模态分解（EMD）等方法被广泛应用于电机故障特征提取。Nandi 等[nandi2005condition]对基于电流信号分析的电机故障诊断方法进行了系统综述，指出定子电流信号分析（MCSA）是最具工程应用前景的非侵入式诊断方法之一。

在模式识别方面，支持向量机（SVM）、随机森林（RF）、k 近邻（KNN）等传统机器学习方法被广泛用于故障分类。Lei 等[lei2020applications]提出了基于集成经验模态分解和多尺度熵的轴承故障诊断方法，取得了较好的诊断效果。然而，这些方法都需要先进行人工特征提取，特征选择的好坏直接影响诊断性能。

1.2.2 基于深度学习的电机故障诊断研究

随着深度学习技术的发展，越来越多的研究者将其应用于电机故障诊断领域。Jia 等[jia2016deep]首次将深度神经网络（DNN）应用于旋转机械故障诊断，验证了深度学习

在故障特征自动提取方面的优势。Zhang 等[zhang2018deep]提出了一种基于卷积神经网络（CNN）的轴承故障诊断方法，直接从原始振动信号中学习故障特征，实现了端到端的故障诊断。

在迁移学习方面，Li 等[li2020systematic]提出了基于迁移学习的跨工况轴承故障诊断方法，利用源域数据预训练模型，再在目标域上进行微调，有效解决了变工况下的故障诊断问题。Wen 等[wen2020new]提出了一种基于迁移学习和残差网络的故障诊断方法，在跨设备诊断任务中取得了较好的效果。

1.2.3 现有研究的不足

尽管基于深度学习的电机故障诊断方法取得了一定的进展，但仍存在以下不足：（1）大多数研究集中在公开数据集上的验证，缺乏在实际工业场景中的应用验证；（2）小样本条件下的诊断精度有待提高；（3）多故障耦合条件下的诊断能力不足；（4）模型的可解释性和可靠性有待增强。

1.3 本文主要研究内容

本文针对电机故障诊断中特征提取困难、小样本诊断精度低等问题，开展基于深度学习的电机故障诊断方法研究。主要研究内容包括：

1. 电机故障振动信号分析。分析电机常见故障的振动信号特征，建立电机故障振动信号数据集，为后续研究提供数据基础。
2. 基于 CNN 的端到端故障诊断方法。设计适用于一维振动信号的 CNN 网络结构，实现从原始信号到故障类别的端到端诊断。
3. 基于迁移学习的小样本故障诊断方法。引入迁移学习策略，利用源域数据预训练模型，在目标域小样本条件下进行微调，提高诊断精度。
4. 基于多尺度特征融合的故障诊断方法。设计多尺度特征融合网络，提取不同层次的故障特征，提高模型对多类型故障的识别能力。

1.4 本文组织结构

本文共分为六章，各章内容安排如下：

第一章为绪论，介绍研究背景与意义，综述国内外研究现状，明确本文的研究内容和组织结构。

第二章为相关理论基础，介绍电机故障类型与机理、深度学习基础理论、卷积神经网络和迁移学习的基本原理。

第三章为基于 CNN 的端到端电机故障诊断方法，设计适用于振动信号的 CNN 网络结构，在公开数据集上验证方法的有效性。

第四章为基于迁移学习的小样本电机故障诊断方法，提出迁移学习策略，解决小样本条件下的诊断问题。

第五章为基于多尺度特征融合的电机故障诊断方法，设计多尺度特征融合网络，提高多类型故障的诊断精度。

第六章为总结与展望，总结本文的主要工作和创新点，分析存在的不足，并对未来研究方向进行展望。

2 相关理论基础

2.1 电机故障类型与机理

电机在运行过程中可能发生多种类型的故障，根据故障部位和原因的不同，主要分为以下几类：

2.1.1 轴承故障

轴承是电机中最容易发生故障的部件之一。常见的轴承故障包括外圈故障、内圈故障、滚动体故障和保持架故障。轴承故障的振动信号具有周期性冲击特征，其故障特征频率可由以下公式计算：

$$f_{BPFI} = \frac{N_b}{2} f_r \left(1 + \frac{d}{D}\cos\alpha\right) \tag{2-1}$$

其中，N_b 为滚动体数量，f_r 为转频，d 为滚动体直径，D 为轴承节径，α 为接触角。

2.1.2 转子故障

转子故障主要包括转子不平衡、转子不对中和转子弯曲等。转子不平衡是最常见的转子故障，其振动特征表现为 1 倍转频分量幅值增大。转子不对中则会产生 2 倍转频分量，并可能激发高次谐波。

2.2 深度学习基础理论

2.2.1 卷积神经网络

卷积神经网络（CNN）是深度学习中最重要的网络结构之一，特别适合处理具有网格结构的数据。一维 CNN 的基本操作包括：

（1）卷积运算：第 l 层第 i 个特征图的第 j 个元素计算为

$$x_{i,j}^{(l)} = f\left(\sum_{m=1}^{M}\sum_{k=1}^{K} w_{i,m,k}^{(l)} x_{m,j+k-1}^{(l-1)} + b_i^{(l)}\right) \tag{2-2}$$

其中，$w_{i,m,k}^{(l)}$ 为卷积核权重，$b_i^{(l)}$ 为偏置，$f(\cdot)$ 为激活函数，K 为卷积核大小。

（2）池化运算：最大池化和平均池化是两种常用的池化方式，用于降低特征图维度，增强特征的平移不变性。

（3）全连接层：将卷积和池化层提取的特征进行整合，输出分类结果。

2.2.2 迁移学习

迁移学习是利用源域 $\mathcal{D}_S$ 上学习到的知识来帮助目标域 $\mathcal{D}_T$ 上的学习任务。当 $\mathcal{D}_S \neq \mathcal{D}_T$ 或 $\mathcal{T}_S \neq \mathcal{T}_T$ 时，迁移学习能够有效解决目标域数据不足的问题。

基于预训练微调的迁移学习策略包括两个阶段：（1）预训练阶段：在源域数据上训练模型，学习通用的特征表示；（2）微调阶段：冻结部分网络层，在目标域数据上微调剩余层，适应目标任务。

2.3 本章小结

本章介绍了电机故障诊断和深度学习的相关理论基础，包括电机常见故障类型及其振动特征、卷积神经网络的基本结构和迁移学习的基本原理，为后续章节的方法研究奠定了理论基础。

3 基于 CNN 的端到端电机故障诊断方法

3.1 方法概述

传统的电机故障诊断方法需要先进行人工特征提取，再利用分类器进行故障识别，特征提取的好坏直接影响诊断性能。本章提出一种基于卷积神经网络的端到端故障诊断方法，直接从原始振动信号中自动学习故障特征，实现从原始信号到故障类别的端到端诊断。

3.2 网络结构设计

针对一维振动信号的特点，本文设计了一维 CNN 网络结构，主要包括以下模块：

3.2.1 输入层

输入为原始振动信号序列 $\mathbf{x} = [x_1, x_2, \ldots, x_T]$，其中 T 为信号长度。为了适应不同长度的信号，采用滑动窗口方式对信号进行分段处理。

3.2.2 特征提取模块

特征提取模块由多个卷积块级联组成，每个卷积块包含一维卷积层、批归一化层、ReLU 激活函数和最大池化层：

$$\mathbf{h}^{(l)} = \mathrm{MaxPool}\left(\mathrm{ReLU}\left(\mathrm{BN}\left(\mathbf{W}^{(l)} * \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\right)\right)\right) \tag{3-1}$$

其中，$\mathbf{W}^{(l)}$ 和 $\mathbf{b}^{(l)}$ 为第 l 层卷积核权重和偏置，BN 为批归一化操作，$*$ 为卷积运算。

3.2.3 分类模块

分类模块由全局平均池化层和全连接层组成，输出各故障类别的概率分布：

$$\hat{y} = \mathrm{softmax}\left(\mathbf{W}_{fc} \cdot \mathrm{GAP}(\mathbf{h}^{(L)}) + \mathbf{b}_{fc}\right) \tag{3-2}$$

3.3 实验设置与结果分析

3.3.1 数据集

采用凯斯西储大学（CWRU）轴承数据集进行实验验证。该数据集包含正常、外圈故障、内圈故障和滚动体故障四种类别，故障直径分别为 0.1778mm、0.3556mm 和 0.5334mm，共 10 种状态。

3.3.2 实验结果

表 3-1 不同方法在 CWRU 数据集上的诊断准确率

方法	输入	准确率 (%)
SVM + 人工特征	统计特征	89.2
RF + 人工特征	统计特征	91.5
DNN	原始信号	93.8
本文 CNN	原始信号	97.3

实验结果表明，本文提出的 CNN 方法在 CWRU 数据集上达到了 97.3% 的诊断准确率，优于传统的 SVM 和 RF 方法，验证了端到端学习方法的有效性。

3.4 本章小结

本章提出了基于 CNN 的端到端电机故障诊断方法，设计了一维 CNN 网络结构，直接从原始振动信号中学习故障特征。实验结果表明，该方法在 CWRU 数据集上取得了 97.3% 的诊断准确率，优于传统方法。

4 基于迁移学习的小样本电机故障诊断方法

4.1 问题分析

在实际工业场景中，电机故障样本往往非常稀缺，难以满足深度学习模型的大样本训练需求。迁移学习通过利用源域数据上学习到的知识来帮助目标域上的学习任务，是解决小样本问题的有效途径。

4.2 迁移学习策略设计

4.2.1 源域与目标域定义

设源域 $\mathcal{D}_S = \{(\mathbf{x}_i^S, y_i^S)\}_{i=1}^{N_S}$ 为实验室条件下采集的充足标注数据，目标域 $\mathcal{D}_T = \{(\mathbf{x}_j^T, y_j^T)\}_{j=1}^{N_T}$ 为工业现场采集的少量标注数据，其中 $N_T \ll N_S$。

4.2.2 预训练-微调策略

本文采用预训练-微调的迁移学习策略：

（1）预训练阶段：在源域数据上训练 CNN 模型，学习通用的振动信号特征表示。使用交叉熵损失函数：

$$\mathcal{L}_{pre} = -\frac{1}{N_S}\sum_{i=1}^{N_S}\sum_{c=1}^{C} y_{i,c}^S \log \hat{y}_{i,c}^S \tag{4-1}$$

（2）微调阶段：冻结前两层卷积块，仅微调后两层和全连接层，使用目标域数据训练：

$$\mathcal{L}_{ft} = -\frac{1}{N_T}\sum_{j=1}^{N_T}\sum_{c=1}^{C} y_{j,c}^T \log \hat{y}_{j,c}^T + \lambda\|\theta\|_2^2 \tag{4-2}$$

其中 λ 为正则化系数，θ 为可训练参数。

4.3 实验结果与分析

4.3.1 小样本实验设置

从 CWRU 数据集中随机选取不同比例的样本作为训练集，测试不同方法在小样本条件下的诊断性能。

4.3.2 实验结果

表 4-1 不同方法在小样本条件下的诊断准确率 (%)

训练样本数/类	CNN	DNN	SVM	本文方法
10	72.5	68.3	75.1	85.6
20	81.2	76.8	80.3	90.2
50	89.7	85.4	86.5	94.1
100	94.3	91.6	89.8	96.8

实验结果表明，在每类仅 10 个训练样本的极端小样本条件下，本文方法仍能达到 85.6% 的诊断准确率，显著优于直接训练的 CNN 方法（72.5%），验证了迁移学习策略

在小样本故障诊断中的有效性。

4.4 本章小结

本章提出了基于迁移学习的小样本电机故障诊断方法，采用预训练-微调策略解决工业场景中小样本条件下模型训练困难的问题。实验结果表明，该方法在小样本条件下显著优于直接训练的方法。

5 基于多尺度特征融合的电机故障诊断方法

5.1 问题分析

不同类型的电机故障在振动信号中表现出不同的尺度特征。例如，轴承局部故障产生高频冲击信号，而转子不平衡则表现为低频振动。单一尺度的特征提取难以充分描述不同故障的特征，影响诊断精度。

5.2 多尺度特征融合网络设计

5.2.1 网络总体结构

本文设计了一种多尺度特征融合网络（MSFF-Net），其核心思想是利用不同大小的卷积核提取不同尺度的特征，并通过特征融合模块将多尺度特征进行有效整合。

5.2.2 多尺度特征提取模块

多尺度特征提取模块采用并行结构，使用三种不同大小的卷积核（$K = 3, 5, 7$）分别提取不同尺度的特征：

$$\mathbf{h}_k^{(l)} = \mathrm{Conv1D}_{K=k}\left(\mathbf{h}^{(l-1)}\right), \quad k \in \{3, 5, 7\} \tag{5-1}$$

5.2.3 特征融合模块

特征融合模块将不同尺度的特征进行拼接和加权融合：

$$\mathbf{h}_{fused}^{(l)} = \sum_{k \in \{3,5,7\}} \alpha_k \cdot \mathbf{h}_k^{(l)} \tag{5-2}$$

其中 α_k 为可学习的注意力权重，满足 $\sum_k \alpha_k = 1$。

5.3 实验结果与分析

5.3.1 实验设置

在 CWRU 数据集和江南大学轴承数据集上分别进行实验，验证 MSFF-Net 的有效性。

5.3.2 对比实验结果

表 5-1 不同方法在两个数据集上的诊断准确率 (%)

方法	CWRU	江南大学
标准 CNN	97.3	91.2
多分支 CNN	98.1	93.5
ResNet-1D	97.8	92.8
本文 MSFF-Net	99.2	95.6

实验结果表明，本文提出的 MSFF-Net 在两个数据集上均取得了最优的诊断准确率，在 CWRU 数据集上达到 99.2%，在江南大学数据集上达到 95.6%，验证了多尺度特征融合策略的有效性。

5.4 本章小结

本章提出了基于多尺度特征融合的电机故障诊断方法，设计 MSFF-Net 网络结构，利用不同大小的卷积核提取多尺度特征，并通过注意力机制进行特征融合。实验结果表明，该方法在两个数据集上均取得了优于对比方法的诊断精度。

6 总结与展望

6.1 本文工作总结

本文针对电机故障诊断中特征提取困难、小样本诊断精度低等问题，开展了基于深度学习的电机故障诊断方法研究，主要工作和创新点总结如下：

（1）提出了一种基于 CNN 的端到端电机故障诊断方法。设计了一维 CNN 网络结构，直接从原始振动信号中自动学习故障特征，避免了传统方法中复杂的人工特征提取过程，在 CWRU 数据集上达到了 97.3% 的诊断准确率。

（2）提出了基于迁移学习的小样本电机故障诊断方法。采用预训练-微调策略，利用源域数据预训练模型，在目标域小样本条件下进行微调，在每类仅 10 个训练样本的条件下仍能达到 85.6% 的诊断准确率，显著优于直接训练的方法。

（3）提出了基于多尺度特征融合的电机故障诊断方法。设计 MSFF-Net 网络结构，利用不同大小的卷积核提取多尺度特征，并通过注意力机制进行特征融合，在 CWRU 数据集上达到 99.2% 的诊断准确率，在江南大学数据集上达到 95.6%。

6.2 存在的不足

尽管本文在基于深度学习的电机故障诊断方面取得了一定的成果，但仍存在以下不足：

（1）实验验证主要基于公开数据集，缺乏在实际工业场景中的应用验证。实际工业环境中的噪声干扰、工况变化等因素对诊断性能的影响有待进一步研究。

（2）本文方法主要针对单一故障的诊断，对于多故障耦合的情况尚未进行深入研究。

（3）深度学习模型的可解释性较差，难以满足工业应用中对诊断结果可信度的要求。

（4）模型的实时性有待优化，当前方法在嵌入式设备上的部署和推理速度需要进一步改进。

6.3 未来工作展望

针对上述不足，未来的研究工作可以从以下几个方面展开：

（1）在实际工业场景中采集数据，验证和改进所提方法的工程适用性，研究噪声鲁棒性和工况适应性。

（2）研究多故障耦合条件下的诊断方法，探索多标签分类和故障严重程度评估技术。

（3）研究可解释性深度学习方法，如注意力可视化、类激活映射等，提高诊断结果的可信度。

（4）研究模型轻量化和压缩技术，将深度学习模型部署到嵌入式设备上，实现实时在线故障诊断。

（5）结合数字孪生技术，构建电机故障诊断的虚实交互系统，实现故障预测与健康管理。

致　谢

本论文是在导师李明教授的悉心指导下完成的。从论文选题、研究方案制定到论文撰写，李老师都给予了精心的指导和热情的帮助。李老师严谨的治学态度、渊博的专业知识和创新的研究思维，使我受益匪浅。在此，谨向李老师表示衷心的感谢和崇高的敬意！

感谢上海电机学院电气学院各位老师在研究生学习期间对我的培养和教育，使我在电气工程专业领域打下了扎实的基础。特别感谢在电机故障诊断和深度学习相关课程中给予我帮助的各位老师。

感谢实验室的各位同学在项目开发过程中与我的讨论和协作，他们的建议对改进研究方法起到了重要作用。

最后，衷心感谢我的家人对我学业的支持和鼓励。他们的理解和关爱是我完成学业的强大动力。

附录 A　附录：实验数据与代码

A.1　实验环境

本文实验所使用的软硬件环境如表 A-1所示。

表 A-1 实验环境配置

项目	配置
操作系统	Ubuntu 20.04 LTS
CPU	Intel Core i9-12900K
GPU	NVIDIA RTX 3090 (24GB)
内存	64GB DDR4
Python	3.9
PyTorch	1.12.1
CUDA	11.6

A.2　超参数设置

模型训练的主要超参数设置如表 A-2所示。

表 A-2 模型训练超参数设置

超参数	取值
学习率	0.001
批大小	64
训练轮数	100
优化器	Adam
学习率衰减	StepLR (step=30, γ=0.1)
正则化系数 λ	0.0001

攻读硕士学位期间取得的成果

发表的学术论文

1. 张三, 李明. 基于卷积神经网络的电机轴承故障诊断方法 [J]. 电机与控制学报, 2026, 30(2): 45-52.
2. Zhang S, Li M. Motor fault diagnosis based on multi-scale feature fusion network[C]. Proceedings of the International Conference on Electrical Machines and Systems, 2025: 1-6.

参与的科研项目

1. 国家自然科学基金项目”基于深度学习的电机智能故障诊断方法研究”（项目编号：62XXXXXX），2024-2026，参与。
2. 上海市自然科学基金项目”工业电机健康监测与预测维护技术研究”（项目编号：2XXXXXXX），2024-2025，参与。